

Natural Language Processing avec Python

TP1

Exercice 1 : Prétraitement de Texte

1. Importer la bibliothèque NLTK ou spaCy pour traiter le texte suivant :
"Natural Language Processing is an exciting field! It enables machines to understand human languages and perform various tasks like translation, summarization, and more."
2. Effectuer les étapes suivantes :
 - Tokenization : Séparer le texte en mots.
 - Stemming : Réduire les mots à leur racine (exemple : "processing" → "process").
 - Lemmatization : Convertir les mots à leur forme canonique (exemple : "is" → "be").
 - Suppression des stop words.

Exercice 2 : Similarité entre Mots avec Word2Vec

1. Charger le corpus **Text8** disponible dans la bibliothèque **gensim** ou un autre texte simple.

```
from gensim.models import Word2Vec
from gensim.test.utils import common_texts
```

1. Entraîner un modèle Word2Vec sur le corpus.
2. Utiliser le modèle pour :
 - Trouver les mots les plus similaires à "language".
 - Calculer la similarité entre les mots "machine" et "learning".
 - Résoudre une analogie : "king" - "man" + "woman" = ?

Exercice 3 : Comparaison Word2Vec et TF-IDF

1. Utiliser le même corpus que dans l'exercice précédent.
2. Implémenter une représentation vectorielle avec :
 - **TF-IDF** (avec **scikit-learn**).
 - **Word2Vec** (modèle entraîné à l'exercice 2).
3. Comparer les deux approches pour les tâches suivantes :
 - Identifier les mots les plus similaires à "language".
 - Calculer la similarité entre "machine" et "learning".