

TP02 : Prétraitement d'un corpus de textes

Objectif :

Appliquer des techniques de nettoyage et de normalisation sur un corpus, puis comparer les résultats de la **tokenisation**, du **stemming** et de la **lemmatisation**.

Contexte

corpus = [

"I loved the camera! It takes amazing photos even in low light.",
"Totally disappointed. Battery life is terrible after a week of use.",
"Great value for money. Highly recommended for casual users!",
"Worst product ever. I returned it after two days.",
"Fast delivery, good packaging, but the screen is too small."

]

Travail demandé :◆ **Question 1 : Nettoyage de texte**

- Convertissez tous les textes en **minuscules**
- Supprimez la **ponctuation**, les **liens web**, les **hashtags/mentions**, etc.

◆ **Question 2 : Suppression des stopwords**

- Utilisez la liste de nltk pour supprimer les mots très fréquents sans valeur informative (ex : "the", "is", "for", ...)

◆ **Question 3 : Tokenisation**

- Appliquez deux méthodes de **tokenisation** : nltk et spaCy
- Comparez les résultats sur au moins **un texte** du corpus

◆ **Question 4 : Stemming**

- Appliquez le **PorterStemmer** sur les tokens nettoyés
- Affichez les mots avant et après stemming

◆ **Question 5 : Lemmatisation**

- Appliquez la **lemmatisation** avec spaCy



- Comparez les résultats avec ceux du stemming (quels mots sont mieux traités ?)

◆ **Question 6 : Réflexion**

- Donnez **2 avantages** et **2 inconvénients** du stemming par rapport à la lemmatisation
- Pourquoi le choix de l'une ou l'autre méthode dépend du cas d'usage ?

• **Question 7 : Vocabulaire**

- À partir du corpus nettoyé et lemmatisé, construisez le **vocabulaire unique** (ensemble des mots distincts).
- Quelle est sa taille ?
- Comparez la taille du vocabulaire brut avec celle après nettoyage et lemmatisation.

• ◆ **Question 8 : Fréquence des mots**

- Comptez la **fréquence d'apparition** des mots dans l'ensemble du corpus (après nettoyage).
- Affichez les **5 mots les plus fréquents**.
- Que peut-on déduire sur la thématique des textes ?

• ◆ **Question 9 : Importance du contexte**

- Donnez un **exemple de mot** pour lequel le lemmatiseur a donné un résultat incorrect (s'il y en a).
- Expliquez pourquoi le contexte peut être important pour bien lemmatiser un mot.

• ◆ **Question 10 : Application pratique**

- Si vous deviez utiliser ces textes pour entraîner un **modèle de classification de sentiment** (positif/négatif), quels prétraitements garderiez-vous ? Justifiez vos choix.