

TP03 : Techniques de vectorisation

Introduction :

Dans ce TP, nous explorerons plusieurs techniques de vectorisation utilisées pour transformer du texte brut en une forme numérique, compréhensible par les modèles de machine learning. Nous aborderons deux méthodes classiques (Bag-of-Words et TF-IDF) ainsi que les embeddings de mots avec Word2Vec.

Prérequis :

- Installation des bibliothèques suivantes : NLTK, Gensim, spaCy, scikit-learn.
- Corpus textuel à utiliser : le dataset 20 Newsgroups ou un autre petit jeu de données textuelles.

Partie 1 : Vectorisation classique

Vectorisation Bag-of-Words (BoW) :

- Utilisez CountVectorizer de scikit-learn pour transformer un corpus en une matrice de fréquence des mots.
- Visualisez la matrice résultante et interprétez les dimensions.
- Exercice 1 : Écrivez du code pour vectoriser un texte et afficher la matrice résultante avec les mots correspondants.

Vectorisation TF-IDF :

- Appliquez TfidfVectorizer pour calculer la fréquence inverse des documents et comparez les résultats avec BoW.
- Exercice 2 : Comparez les matrices générées par BoW et TF-IDF pour un petit échantillon de texte. Quel impact a la normalisation de TF-IDF sur les résultats ?

Partie 2 : Word Embeddings

- Introduction à Word2Vec (Word Embeddings) :



- Utilisez la bibliothèque Gensim pour entraîner un modèle Word2Vec sur un petit corpus.
- Explorez les propriétés des embeddings générés (par exemple, la similarité entre des mots).
- Exercice 3 : Entraînez un modèle Word2Vec sur votre corpus et affichez les mots les plus proches d'un mot donné (par exemple, « roi » et « reine »).

Visualisation des embeddings :

- Utilisez t-SNE pour réduire la dimensionnalité des embeddings et visualisez les mots dans un espace 2D.
- Exercice 4 : Réduisez la dimensionnalité des embeddings Word2Vec à 2 dimensions avec t-SNE et visualisez les relations sémantiques des mots.

Partie 3 : Comparaison des techniques

- Comparaison entre les méthodes :
- Comparez les résultats des méthodes BoW, TF-IDF et Word2Vec en fonction des tâches NLP (comme la similarité entre mots).
- Exercice 5 : Calculez la similarité cosinus entre quelques mots pour chaque méthode de vectorisation et comparez les résultats.

