

TP04 : Implémentation de Word Embeddings sur un corpus de textes.

Objectifs pédagogiques :

- Apprendre à entraîner un modèle Word2Vec sur un corpus de texte.
- Comprendre le fonctionnement des embeddings de mots et leur utilité dans les tâches de NLP.
- Visualiser les relations sémantiques entre les mots dans l'espace vectoriel.

Pré-requis :

- **Python** (version 3.x)
- **Gensim** : Bibliothèque pour entraîner des modèles Word2Vec.
- **NLTK** ou **spaCy** : Pour prétraiter le texte (tokenisation, nettoyage).
- **Matplotlib** et **Seaborn** : Pour la visualisation des embeddings.

Partie 1 : Préparation du corpus

1. Chargement et prétraitement du corpus :
2. Téléchargez un corpus textuel comme 20 Newsgroups, IMDB (pour les critiques de films), ou un autre jeu de données textuelles.
3. Effectuez un prétraitement sur le texte : tokenisation, suppression des stopwords, mise en minuscules, suppression de la ponctuation et des chiffres.
4. Exercice 1 : Utilisez NLTK ou spaCy pour prétraiter un échantillon de texte (par exemple, une liste de phrases) et afficher le texte nettoyé sous forme de liste de tokens.

Partie 2 : Entraînement du modèle Word2Vec

5. Entraîner un modèle Word2Vec sur le corpus prétraité :
 - a. Utilisez la bibliothèque **Gensim** pour entraîner un modèle **Word2Vec**.

Paramètres importants :

- `vector_size` : la dimension des vecteurs.
- `window` : la taille de la fenêtre contextuelle.



- `min_count` : le nombre minimum d'occurrences d'un mot pour qu'il soit pris en compte.
 - `sg` : méthode de formation (0 pour CBOW, 1 pour Skip-gram).
6. Exercice 2 : Entraînez un modèle Word2Vec sur un petit corpus de texte et sauvegardez-le pour une utilisation future.

Partie 3 : Exploration des embeddings

7. Explorer les relations sémantiques :
8. Après l'entraînement, vous pouvez interroger le modèle pour obtenir les mots les plus similaires à un mot donné, ou encore explorer les relations entre différents mots.
9. Exercice 3 : Trouvez les mots les plus similaires à un mot spécifique (par exemple, « chat »), et comparez la similarité entre deux mots (par exemple, « chat » et « chien »).

Partie 4 : Visualisation des embeddings

Visualisation des embeddings dans un espace 2D :

10. Utilisez **t-SNE** pour réduire la dimensionnalité des embeddings et visualisez les mots dans un espace 2D.
11. Exercice 4 : Sélectionnez un sous-ensemble de mots (par exemple, les mots "chat", "chien", "souris", "manger", etc.) et réduisez la dimensionnalité pour les visualiser.

